En este experimento correremos el mejor par de hiperparametros para kNN+PCA con distintos tamanios de dataset. Primero corremos un script para el build de las librerias de c++ como modulos de python. Analizaremos con mas profunidad estos resultados en el informe dado junto a esta entrega.

```
In [ ]: !sh build.sh
```

Importamos dependencias

```
import metnum
import pandas as pd
import numpy as np
from sklearn.metrics import accuracy_score
from pathlib import Path
import time
from utils import get_MNIST_XY
from sklearn.datasets import fetch_openml
import matplotlib.pyplot as plt
from sklearn.model_selection import KFold
```

Obtenemos los X e y de MNIST, shuffleados con 70000 elementos.

```
In [26]: X_all, y_all = get_MNIST_XY(0.8, 70000)
```

Seteamos los tamanios de dataset a probar

```
In [27]: cant_imagenes = [100, 500, 1000, 5000, 10000, 20000, 50000, 70000]
```

```
In [28]:
          resultados = []
          for j, cant in enumerate(cant_imagenes):
              y = y all.astype(int)[:cant]
              X = X all.astype(int)[:cant]
              kf = KFold(n_splits=5, shuffle=True)
              accuracies by split = 0
              for train_index, test_index in kf.split(X):
                  X_train, X_val = X[train_index], X[test_index]
                  y_train, y_val = y[train_index], y[test_index]
                  pca = metnum.PCA(19)
                  pca.fit(X train)
                  X train PCA = pca.transform(X train)
                  X_val_PCA = pca.transform(X_val)
                  clf metnum = metnum.KNNClassifier(3)
                  clf_metnum.fit(X_train_PCA, y_train)
                  acc = accuracy_score(clf_metnum.predict(X_val_PCA), y_val)
                  accuracies_by_split += acc
              resultados.append(accuracies_by_split / 5)
```

```
In [29]: resultados
```

```
0.9666599999999999
0.9703714285714286]

In [31]: 
   plt.bar(['100', '500', '1000', '5000', '10000', '20000', '50000', '70000'], r
    plt.ylim(0.4)
    plt.ylabel('Accuracy')
    plt.xlabel('Tamaño dataset')
    plt.title(f'Accuracies para k = 3 y alpha = 19 para distintos tamanios de dat
    for i in range(8):
        plt.text(i, resultados[i], format(resultados[i], '.3f') , ha = 'center')
    plt.show()
```

0.8460000000000001,
0.894000000000001,

0.9553499999999999,

0.9308, 0.9436,

Accuracies para k = 3 y alpha = 19 para distintos tamanios de dataset con 5-Fold

